Báo Cáo GPU FinOps

Day 25 - GPU FinOps & Cost Optimization

Le Huy Hong Nhat

MSSV: 2A202600099

13/05/2026

Tóm tắt kết quả. Mock GPU platform được chạy bằng Docker Compose local và notebook Kaggle gọi API qua tunnel. Real GPU training chạy trên Tesla T4. AMP nhanh hơn FP32 2.11x và giảm chi phí 52.7%. Advanced analysis cho thấy expected project cost là $4261.44 và roadmap optimization có thể tiết kiệm 87.8%.

Mục lục

1 Giới thiệu **2**
1.1 Mục tiêu của bài lab 2
1.2 Tổng quan về GPU FinOps 2

2 Phân tích từng phần **2**
2.1 Part 1-7: Mock cluster analysis 2
2.2 Part 8: Real GPU training 6
2.3 Part 8.5: Advanced analysis 8

3 Kết luận và học hỏi **12**
3.1 Những kỹ năng FinOps đã học 12
3.2 Các chiến lược cost optimization hiệu quả 12
3.3 Ứng dụng thực tế trong projects 12

1 Giới thiệu

1.1 Mục tiêu của bài lab

Bài lab xây dựng một quy trình GPU FinOps end-to-end, bao gồm quan sát tài nguyên GPU, ghi nhận billing theo workload, mô phỏng spot/preemptible instances, đánh giá autoscaling, phân tích waste và tối ưu chi phí thông qua mixed precision, scheduling, spot instances và capacity planning.

Mục tiêu cụ thể:

- Theo dõi trạng thái GPU cluster: node count, busy/idle GPUs, utilization, memory và power draw.
- Gắn workload với billing record để hiểu chi phí theo từng job/project.
- Mô phỏng spot instances và preemption để đánh giá savings/risk trade-off.
- Dùng autoscaling policy để phản ứng với utilization threshold.
- Đo real GPU training trên Tesla T4 và so sánh FP32 với Mixed Precision AMP.
- Xây dựng advanced cost forecast, optimization roadmap và budget decision.

1.2 Tổng quan về GPU FinOps

GPU FinOps là thực hành quản trị chi phí GPU dựa trên dữ liệu vận hành. Điểm cốt lõi không chỉ là giảm giá mỗi giờ GPU, mà là tối ưu toàn bộ cost-performance: tăng utilization, giảm idle waste, chọn đúng GPU type, dùng spot cho workload chịu được preemption, và đo chi phí theo workload thay vì chỉ nhìn tổng hóa đơn.

Trong bài lab này, kiến trúc gồm hai phần:

- **Local Docker services**: gateway, gpu-node-manager, billing-api, spot-manager, autoscaler và cost-tracker.
- **Remote notebook trên Kaggle**: chạy experiment, gọi local gateway qua tunnel và thực hiện real GPU training.

2 Phân tích từng phần

2.1 Part 1-7: Mock cluster analysis

Cluster monitoring insights

Mock cluster ban đầu có 9 nodes với 18 GPUs. Trong snapshot monitoring:

Metric	Giá trị
Total GPUs	18
Busy GPUs	13
Idle GPUs	5
Average utilization	56.7%
Memory used / capacity	252.1 GB / 448.0 GB
Total power draw	1417 W
Node count	9

Bảng 1: Cluster metrics ban đầu.

Kết quả này cho thấy cluster đang có workload thật sự, nhưng vẫn còn idle capacity. Sau khi submit thêm workloads, cluster đạt 18/18 GPUs busy với utilization 79.2%. Điều này tạo đủ áp lực để kiểm thử autoscaling policy.

Cost tracking observations

Billing summary sau workload submission:

Metric	Giá trị
Total cost	$5.2869
Total savings	$5.5380
Budget used	5.3%
Alert status	OK

Bảng 2: Billing summary của mock workload.

Cost tracker ghi nhận 5 snapshots với mỗi interval có total cost $0.049722, idle cost $0.001944 và waste 3.9%. Waste report tổng hợp cho thấy average waste 4.1%, severity LOW, nhưng potential monthly saving lên đến $503.88. Điều này minh họa một nguyên tắc quan trọng của GPU FinOps: idle waste nhỏ theo từng interval vẫn có thể thành chi phí lớn nếu kéo dài.

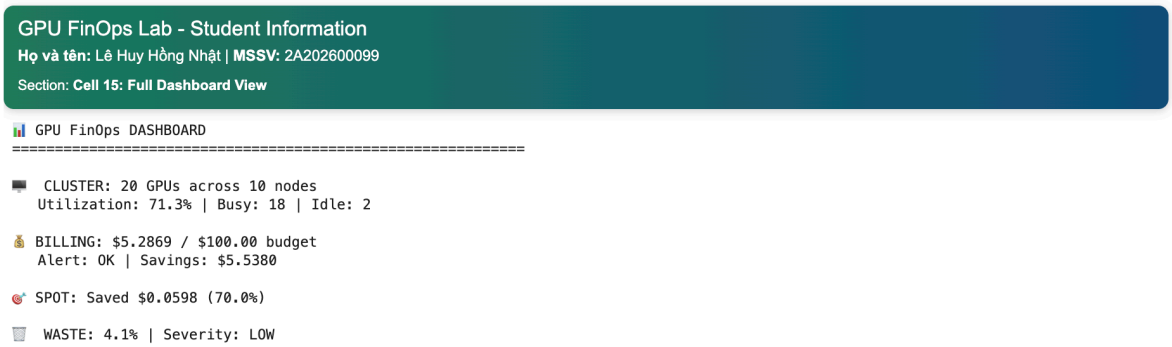

Hình 1: Mock FinOps dashboard: cluster, billing, spot và waste.

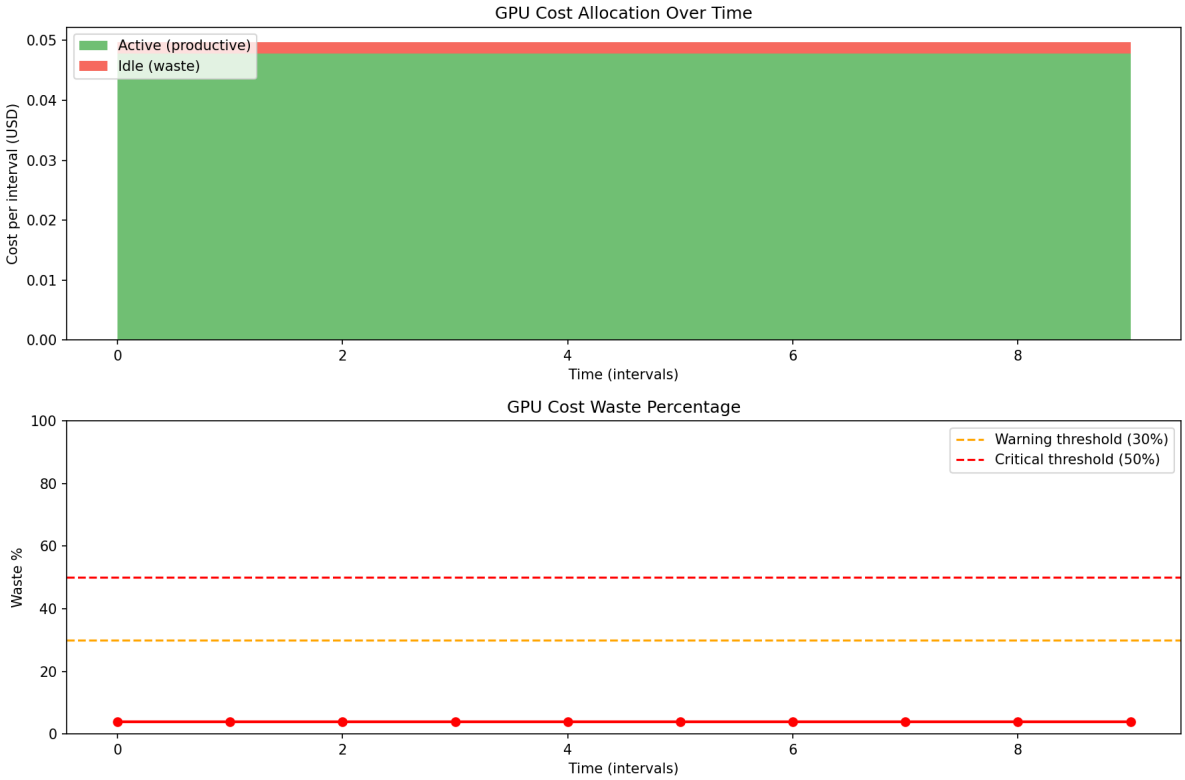

Hình 2: Time-series cost tracking: active cost, idle cost và waste percentage.

Spot instance savings analysis

Spot pricing và preemption workflow cho kết quả:

Metric	Giá trị
T4 spot price	$0.2500/hr
A100 spot price	$2.8853/hr
V100 spot price	$1.5778/hr
Spot requests	3 requests granted
Preemption event	1 instance preempted, 5 still active
Spot cost	$0.0167
On-demand equivalent	$0.0557
Savings	$0.0390 (70.0%)

Bảng 3: Spot/preemptible savings analysis.

Spot instances tiết kiệm lớn nhưng có rủi ro preemption. Vì vậy chiến lược hợp lý là dùng spot cho batch job, training có checkpoint hoặc workload retryable; không nên dùng mặc định cho workload latency-critical hoặc không chịu được interruption.

Autoscaling behavior

Autoscaling policy được update với scale-up threshold 70.0%, scale-down threshold 25.0%, cooldown 30 giây, min nodes 2 và max nodes 10. Khi utilization đạt 79.2%, autoscaler quyết định `SCALE_UP`, tăng cluster từ 9 lên 10 nodes. Sau đó 5 evaluation cycles đều `no_action` với utilization 71.3%, nodes 10 -> 10.

Kết quả này cho thấy autoscaler hoạt động đúng theo threshold, nhưng cũng chỉ ra một điểm cần quản trị: threshold phải được cân bằng để tránh scale-up quá nhanh gây tăng cost hoặc scale-down quá mạnh gây queue workload.

Waste analysis và recommendations

Waste report:

- Average waste: 4.1%.
- Total idle cost: $0.019440.
- Total cost: $0.479720.
- Potential monthly save: $503.88.
- Severity: LOW.

Recommendations gồm:

- **USE_SPOT**: chuyển workload fault-tolerant sang spot instances để tiết kiệm 60-70%.
- **SCHEDULING**: chạy job không gấp trong off-peak hours để tận dụng spot price thấp hơn.

Complete workflow cuối cùng ghi nhận total spend $5.4560, total saved $5.6604, budget usage 5.5% và alert OK.

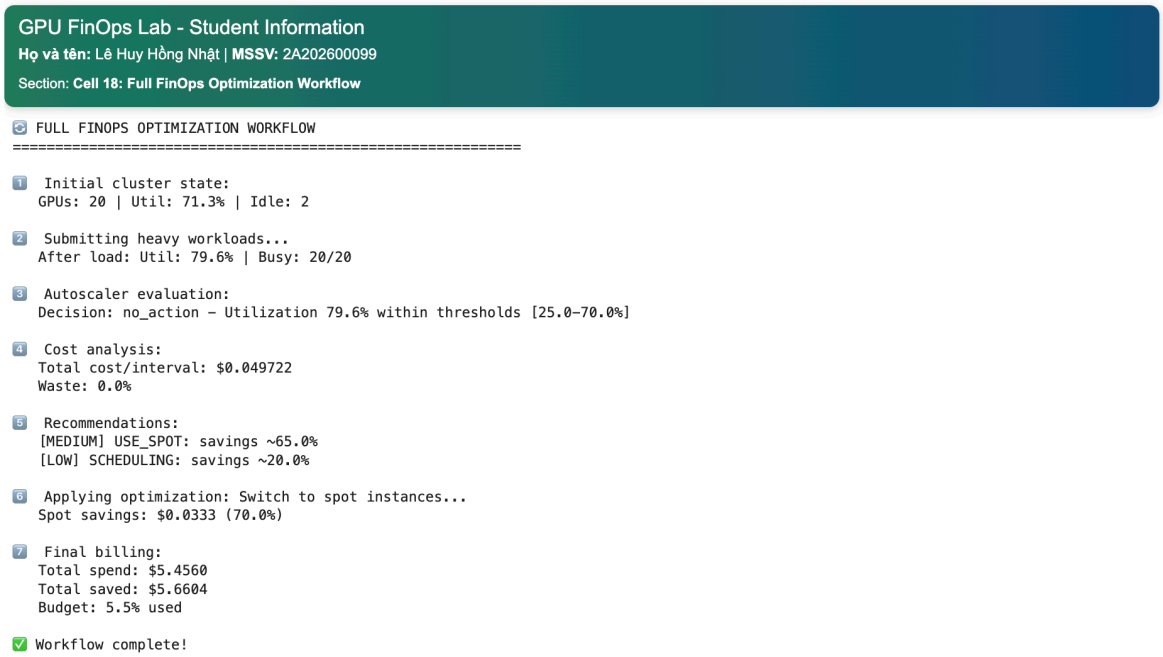

Hình 3: Complete FinOps workflow từ monitoring đến final billing.

2.2 Part 8: Real GPU training

Notebook chạy real GPU trên Tesla T4:

Metric	Giá trị
GPU	Tesla T4
Memory	15.6 GB
Compute capability	7.5
PyTorch	2.10.0+cu128
CUDA build	12.8
Device	cuda

Bảng 4: Thông tin real GPU runtime.

FP32 vs Mixed Precision AMP comparison

Metric	FP32	AMP	Improvement
Total time	117.3s	55.5s	2.11x faster
Peak memory	0.82 GB	0.60 GB	0.22 GB saved
Estimated cost	$0.011399	$0.005392	$0.006007 saved
Cost saving	–	–	52.7%
Average GPU util	97.3%	95.1%	high utilization
Average power	67.1W	66.0W	similar power

Bảng 5: So sánh FP32 và Mixed Precision AMP.

FP32 baseline train 3 epochs với accuracy tăng từ 35.5% lên 69.1%. AMP train 3 epochs với accuracy tăng từ 31.4% lên 63.6%. Trong cùng số epochs, AMP nhanh hơn đáng kể và giảm chi phí 52.7%.

Cost savings achieved

Extrapolated savings:

- 1 ngày training: FP32 $8.40 vs AMP $3.97, tiết kiệm $4.43.
- 1 tuần training: FP32 $58.80 vs AMP $27.81, tiết kiệm $30.99.
- 1 tháng training: FP32 $252.00 vs AMP $119.20, tiết kiệm $132.80.

AMP là chiến lược tối ưu chi phí hiệu quả vì effort thấp, rủi ro thấp và thường không làm giảm chất lượng đáng kể nếu được kiểm chứng bằng validation metrics.

GPU utilization patterns

Cả FP32 và AMP đều có utilization cao, lần lượt 97.3% và 95.1%. Điều này cho thấy experiment đang dùng GPU hiệu quả và không bị bottleneck nặng ở data loading. Telemetry cũng ghi nhận power trung bình khoảng 66-67W.

Hình 4: FP32 vs AMP: time, cost và utilization/epoch comparison.

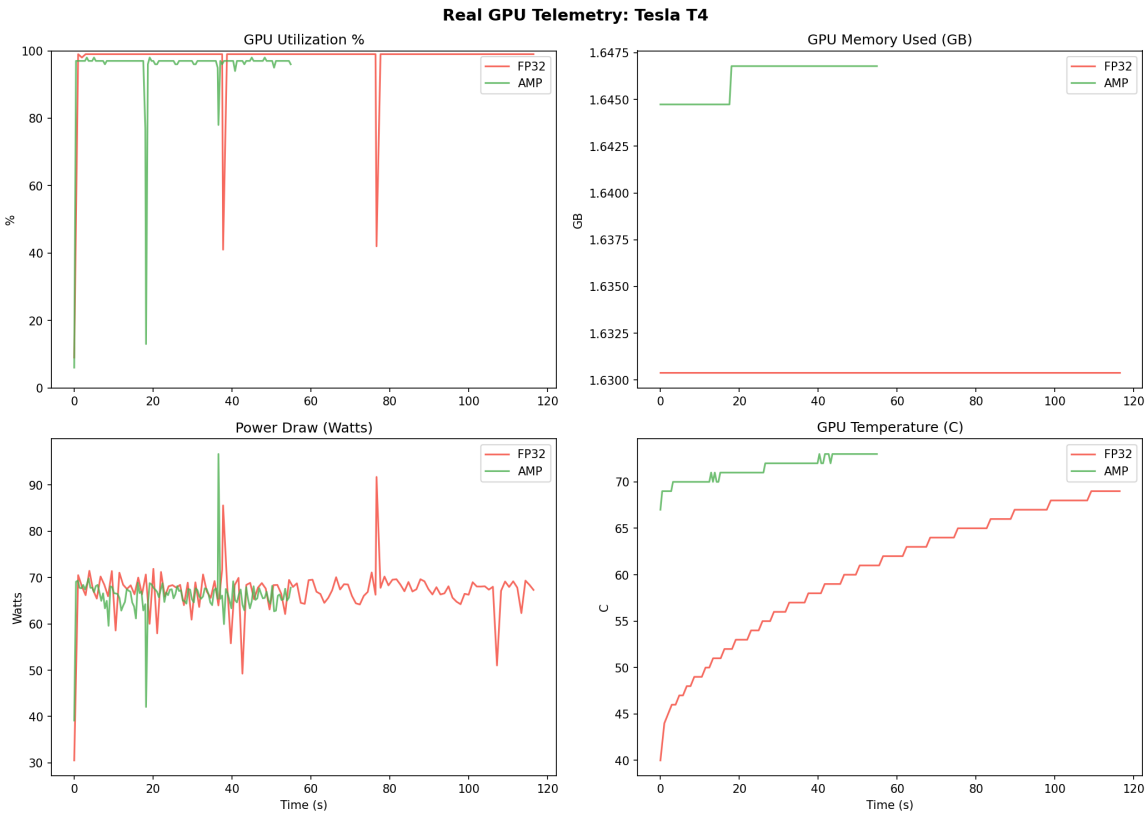

Hình 5: Real GPU telemetry: utilization, memory, power và temperature.

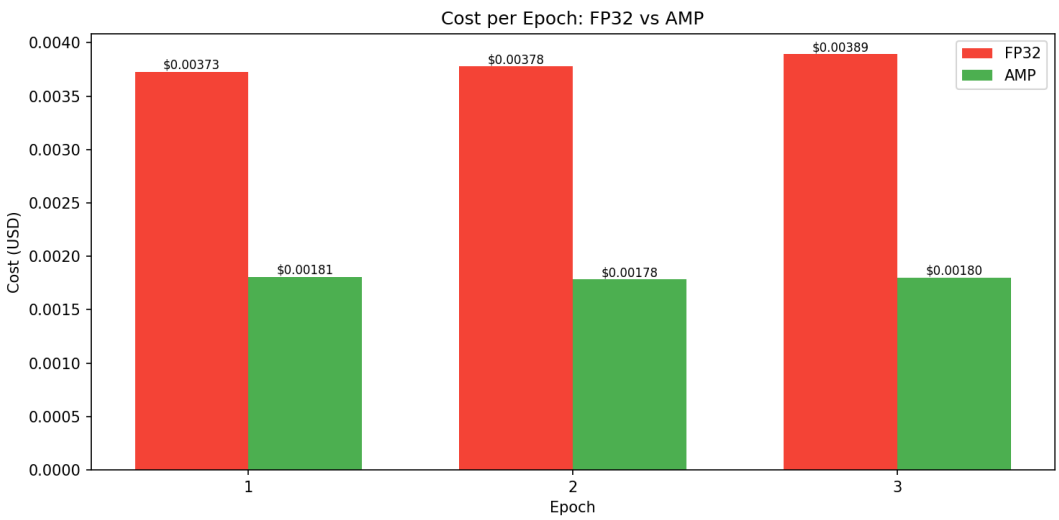

Hình 6: Cost per epoch giữa FP32 và AMP.

2.3 Part 8.5: Advanced analysis

Multi-GPU scaling efficiency

Multi-GPU cost analysis cho thấy:

- Lowest cost: 1x A100 với cost $7.34.
- Fastest run: 8x A100 với runtime 0.36h.

- Best cost/performance: 8x A100 với $1.87/speedup unit.

Kết quả nhấn mạnh rằng scaling không tuyến tính. Thêm GPU giúp giảm runtime nhưng tăng GPU-hour. Vì vậy cần so sánh theo cost-per-performance, deadline và budget thay vì chỉ chọn cấu hình nhanh nhất.

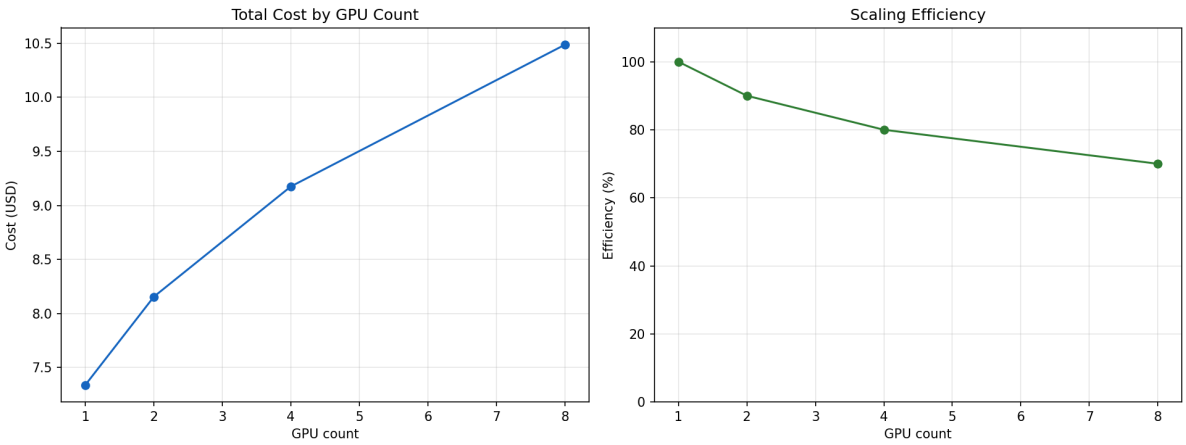

Hình 7: Multi-GPU cost curve và scaling efficiency.

Project cost forecasting

Forecast multi-phase project:

Metric	Giá trị
Base total	$3551.20
Contingency	$710.24 (20%)
Expected total	$4261.44
95% interval	$2913.09 - $5609.79
Best / worst case	$2578.82 - $5233.82

Bảng 6: Project cost forecasting summary.

Expected total vẫn nằm trong mức kiểm soát, nhưng upper confidence interval có thể vượt $5600. Điều này chứng minh cần contingency và confidence interval khi lập budget GPU, đặc biệt cho hyperparameter tuning hoặc phase có uncertainty cao.

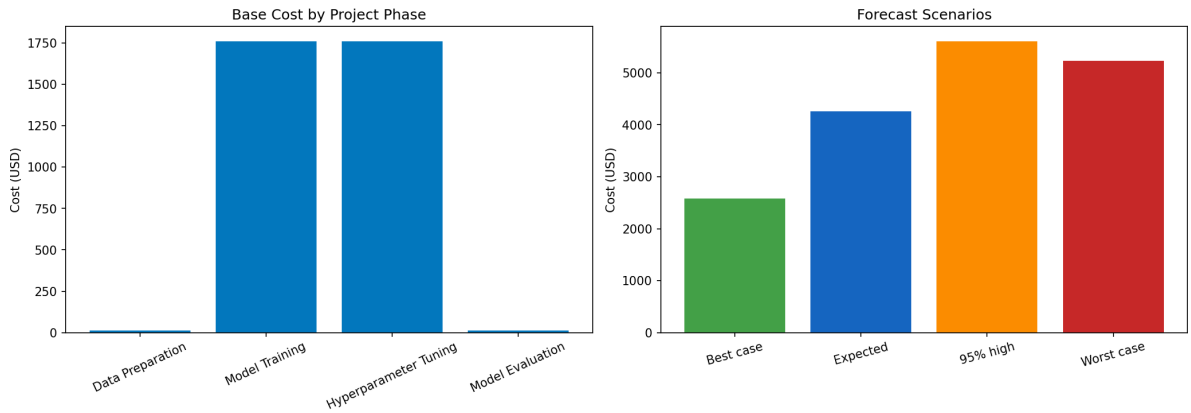

Hình 8: Project forecast theo phase và scenario.

Optimization strategy prioritization

Optimization opportunity analysis bắt đầu từ baseline cost $1468.00. Roadmap tối ưu cuối cùng giảm cost xuống $179.68, tiết kiệm $1288.32 tương đương 87.8%.

Các chiến lược quan trọng:

- Mixed Precision AMP: low effort, low risk, savings cao.
- Optimize Batch Size: cải thiện utilization mà không tăng preemption risk.
- Early Stopping: giới hạn runaway training/tuning cost.
- Spot Instances: savings lớn nhưng cần checkpoint/retry để kiểm soát risk.
- Switch GPU Type: tiềm năng lớn nhưng effort/risk cao hơn.

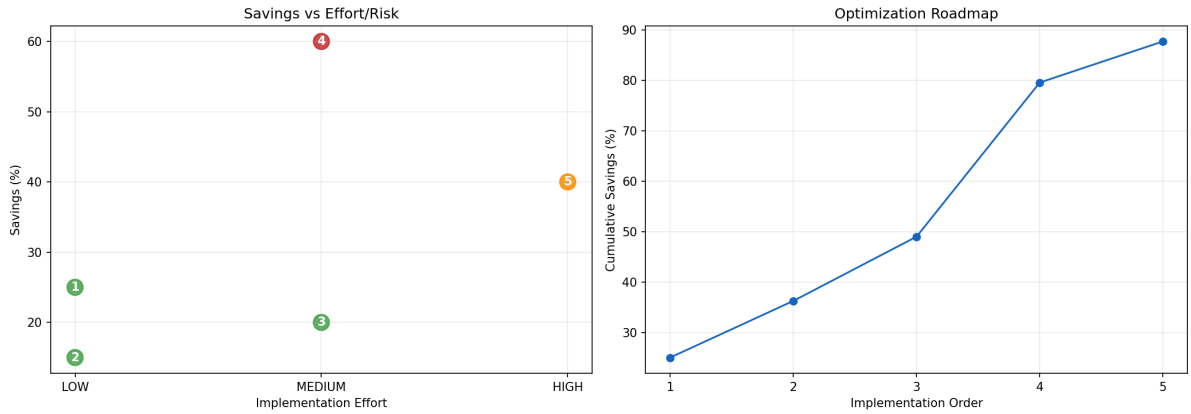

Hình 9: Optimization priority matrix và cumulative savings roadmap.

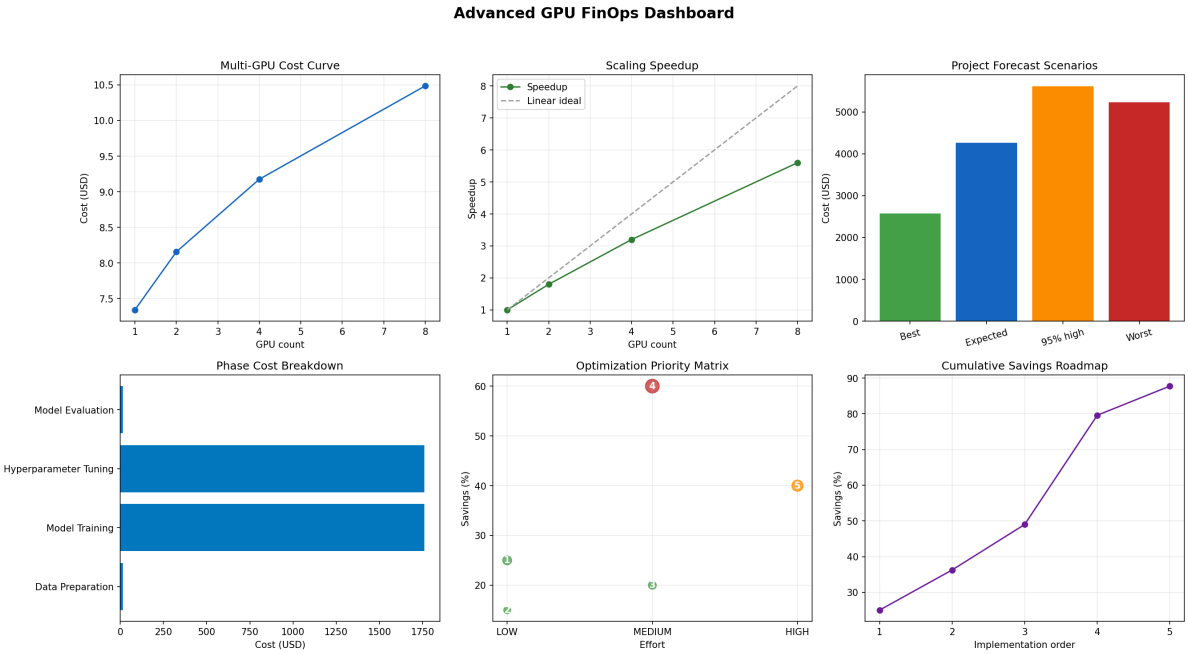

Hình 10: Integrated advanced FinOps dashboard.

Challenge exercise

Challenge scenario là fine-tuning LLM với baseline 8x A100 trong 200h, FP32, on-demand, budget $5000 và deadline 2 tuần. Baseline cost là $5872.00, vượt budget.

Chiến lược được chọn:

- GPU plan: 8x A100.
- Runtime sau scaling analysis: 35.7h, nhỏ hơn deadline 336h.
- Raw GPU cost: $1048.57.
- Forecast before strategy: $1215.52.
- Strategy savings: 61.8%.
- Final expected cost: $464.94.
- 95% interval after optimization: $307.71 - $622.16.
- Verdict: UNDER BUDGET.

GPU FinOps Lab - Student Information
Họ và tên: Lê Huy Hồng Nhật | **MSSV:** 2A202600099
Section: **Cell 31: Challenge Exercise - Cost Optimization Strategy Design**

```
============================================================
CHALLENGE EXERCISE 8.5.5: Design Cost Optimization Strategy
============================================================
CHALLENGE SCENARIO:
   Project:  Large Language Model Fine-tuning
   Baseline: 8x A100 for 200h, FP32, on-demand
   Budget:   $5000.00
   Deadline: 2 weeks
   Baseline cost: $5872.00

Multi-GPU options:
```

	gpu_count	gpu_type	speedup	training_time_hours	total_cost_usd	scaling_efficiency_pct	cost_per_speedup_usd	cost_delta_vs_1gpu_pct
0	1	A100	1.00x	200.0h	$734.00	100.0%	$734.00	+0.0%
1	2	A100	1.80x	111.1h	$815.56	90.0%	$453.09	+11.1%
2	4	A100	3.20x	62.5h	$917.50	80.0%	$286.72	+25.0%
3	8	A100	5.60x	35.7h	$1048.57	70.0%	$187.24	+42.9%

```
Selected compute plan:
   GPU plan:        8x A100
   Runtime:         35.7h <= 336h deadline
   Raw GPU cost:    $1048.57

Selected optimization strategy:
```

	rank	strategy	incremental_savings_usd	remaining_cost_usd	cumulative_savings_usd	cumulative_savings_pct
0	1	Switch to Mixed Precision (AMP)	$262.14	$786.43	$262.14	25.0%
1	2	Optimize Batch Size	$117.96	$668.46	$380.11	36.2%
2	3	Implement Early Stopping	$133.69	$534.77	$513.80	49.0%
3	4	Use Managed Spot for Retryable Jobs Only	$133.69	$401.08	$647.49	61.8%

```
Final forecast:
   Forecast before strategy: $1215.52
   Strategy savings:         61.8%
   Final expected cost:      $464.94
   95% interval after opt:   $307.71 - $622.16
   Budget:                  $5000.00
   Verdict:                 UNDER BUDGET

Justification:
   1. Use AMP first because it is low effort, low risk, and usually preserves model quality.
   2. Optimize batch size before infrastructure changes because it improves utilization without adding preemption risk.
   3. Add early stopping to cap runaway tuning/training cost while monitoring validation quality.
   4. Use spot only for checkpointed/retryable jobs to satisfy the MEDIUM max preemption risk constraint.
   5. Keep the selected GPU count within the 2-week deadline and verify the forecast against the $5000 budget.
```

Hình 11: Challenge strategy: forecast, budget verdict và justification.

3 Kết luận và học hỏi

3.1 Những kỹ năng FinOps đã học

- Đo GPU utilization, memory, power và idle waste để hiểu chi phí thật của GPU platform.
- Gắn workload execution với billing record để tính cost theo project/workload.
- Đánh giá spot/preemptible savings song song với rủi ro preemption.
- Dùng autoscaling policy để giảm over-provisioning và phản ứng với demand.
- So sánh FP32 và AMP theo performance, memory, utilization và USD cost.
- Forecast project cost với uncertainty và contingency thay vì chỉ dùng base cost.

3.2 Các chiến lược cost optimization hiệu quả

- **Mixed Precision AMP**: nhanh hơn 2.11x và tiết kiệm 52.7% cost trong experiment thực tế.
- **Spot instances**: tiết kiệm 70.0% trong mock workflow khi dùng cho workload phù hợp.
- **Autoscaling**: scale-up khi utilization vượt threshold và tránh giữ quá nhiều idle GPU.
- **Waste monitoring**: idle waste 4.1% vẫn có thể quy đổi thành monthly savings đáng kể.
- **Optimization roadmap**: kết hợp nhiều chiến lược cho savings tích lũy 87.8%.

3.3 Ứng dụng thực tế trong projects

Trong project thực tế, workflow này có thể triển khai thành dashboard FinOps liên tục. Mỗi training job nên ghi nhận GPU type, runtime, precision mode, cost, utilization và project owner. Platform

team có thể đặt policy: dùng AMP mặc định nếu validation quality không giảm, dùng spot cho job checkpointed/retryable, đặt budget alert theo project và review định kỳ các workload có utilization thấp hoặc idle cost cao.

Bài lab cũng cho thấy quyết định GPU không nên chỉ dựa vào tốc độ. Cấu hình nhiều GPU cần được so sánh bằng cost-per-performance và confidence interval. Khi deadline lỏng, cấu hình rẻ hơn có thể tốt hơn; khi deadline gấp, cấu hình nhanh hơn vẫn hợp lý nếu forecast nằm trong budget.